

# 数据挖掘与机器学习

潘斌

panbin@nankai.edu.cn

范孙楼227

1

# 上节回顾

- 线性分类器
  - 垂直平分分类器
  - 感知准则
  - 最小错分样本数分类器
  - 最小平方误差分类器
- 贝叶斯派和频率派

# 本节提要

- 贝叶斯分类器
  - 最小错误率Bayes决策
  - 最小风险Bayes决策
  - 最大最小Bayes决策
  - 贝叶斯分类器的设计

# 贝叶斯公式

$$P(\theta|X) = \frac{P(X|\theta) \times P(\theta)}{P(X)}$$

$$P(B_i|A) = \frac{P(B_i) P(A|B_i)}{\sum_{j=1}^n P(B_j) P(A|B_j)}$$

## 4.2 最小错误率Bayes决策

- 4.2.1 问题
- 4.2.2 后验概率
- 4.2.3 决策规则
- 4.2.4 实例
- 4.2.5 其它问题
- 4.2.6 特点

## 4.2.1 问题 (P代表概率, p代表概率密度函数)

- **Bayes**决策已知条件和问题 (先考虑**C = 2**分类问题)
  - 两类问题:  $\omega_1$ 和 $\omega_2$
  - 先验概率:  $P(\omega_1)$  和 $P(\omega_2)$
  - 类条件概率密度函数:  $p(x|\omega_1)$  和 $p(x|\omega_2)$
  - 发生了一个随机事件, 其观察值为: 特征向量 $x$
  - 求最小错误率分类器

## 4. 2. 2 后验概率

- **Bayes**（条件概率）公式
  - $p(x|\omega_1) P(\omega_1) = p(x) P(\omega_1|x)$
  - $p(x|\omega_2) P(\omega_2) = p(x) P(\omega_2|x)$
- 后验概率
  - $P(\omega_1|x) = p(x|\omega_1) P(\omega_1) / p(x)$
  - $P(\omega_2|x) = p(x|\omega_2) P(\omega_2) / p(x)$
  - $p(X) = p(x|\omega_1) P(\omega_1) + p(x|\omega_2) P(\omega_2)$

## 4. 2. 3 决策规则

- 决策规则

- 比较后验概率，取最大值进行类别判断
- 对于未知样本 $\mathbf{x}$ ，若 $P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x})$ ，则 $\mathbf{x} \in \omega_1$
- 若 $P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x})$ ，则 $\mathbf{x} \in \omega_2$



## 4.2.3 决策规则

- 等价规则一 后验概率分子
  - 比较分子 $p(x|\omega_1) P(\omega_1)$  和  $p(x|\omega_2) P(\omega_2)$ ，取最大
  - 对于未知样本 $x$ ，若 $p(x|\omega_1) P(\omega_1) > p(x|\omega_2) P(\omega_2)$ ，则 $x \in \omega_1$
  - 若 $p(x|\omega_1) P(\omega_1) < p(x|\omega_2) P(\omega_2)$ ，则 $x \in \omega_2$

## 4. 2. 3 决策规则

- 等价规则二 似然比

- 定义似然比函数  $l(x) = p(x|\omega_1) / p(x|\omega_2)$
- 对于未知样本  $x$ , 若  $l(x) > P(\omega_2) / P(\omega_1)$ , 则  $x \in \omega_1$
- 若  $l(x) < P(\omega_2) / P(\omega_1)$ , 则  $x \in \omega_2$

## 4. 2. 3 决策规则

- 等价规则三 负对数似然比
  - 定义负对数似然比函数 $h(x) = -\ln l(x) = -\ln p(x|\omega_1) + \ln p(x|\omega_2)$
  - 对于未知样本 $x$ , 若 $h(x) < \ln [P(\omega_1) / P(\omega_2)]$ , 则 $x \in \omega_1$
  - 若 $h(x) > \ln [P(\omega_1) / P(\omega_2)]$ , 则 $x \in \omega_2$

## 4.2.4 实例

- 已知

- 癌细胞图像识别：正常和异常两类（即 $C = 2$ ）
- 已知未知样本特征观察值： $x = 0.5$
- 又已知 $P(\omega_1) = 0.9$ 和 $P(\omega_2) = 0.1$
- 查函数曲线得 $p(0.5|\omega_1) = 0.2$ 和 $p(0.5|\omega_2) = 0.4$   
（可以是先验或学习得到）
- 试对未知样本 $x = 0.5$ 进行分类

## 4.2.4 实例

- 已知

- 癌细胞图像识别：正常和异常两类（即 $C = 2$ ）
- 已知未知样本特征观察值： $x = 0.5$
- 又已知 $P(\omega_1) = 0.9$ 和 $P(\omega_2) = 0.1$
- 查函数曲线得 $p(0.5|\omega_1) = 0.2$ 和 $p(0.5|\omega_2) = 0.4$
- 试对未知样本 $x = 0.5$ 进行分类

解：利用贝叶斯公式，分别计算出  $\omega_1$  及  $\omega_2$  的后验概率。

$$P(\omega_1|x) = \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^2 p(x|\omega_j)P(\omega_j)} = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$
$$P(\omega_2|x) = 1 - p(\omega_1|x) = 0.182$$

根据贝叶斯决策规则式(2-2)，有

$$P(\omega_1|x) = 0.818 > P(\omega_2|x) = 0.182$$

所以合理的决策是把  $x$  归类于正常状态。

## 4.2.5 最小错误率的说明

- 最小错误率的说明（设  $C=2$ ,  $D=1$ ）

- 错误率  $P(e)$  的定义

首先应指出所谓错误率是指平均错误率,以  $P(e)$  来表示,其定义为

$$P(e) = \int_{-\infty}^{\infty} P(e, \mathbf{x}) d\mathbf{x} = \int_{-\infty}^{\infty} P(e|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \quad (2-6)$$

其中  $\int_{-\infty}^{\infty} ( ) d\mathbf{x}$  表示在整个  $d$  维特征空间上的积分。

对两类别问题,从式(2-2)的决策规则可知,如果  $P(\omega_2|\mathbf{x}) > P(\omega_1|\mathbf{x})$ ,则决策应为  $\omega_2$ 。显然在作出决策  $\omega_2$  时,  $\mathbf{x}$  的条件错误概率为  $P(\omega_1|\mathbf{x})$ ;反之,则应为  $P(\omega_2|\mathbf{x})$ 。可表示为

$$P(e|\mathbf{x}) = \begin{cases} P(\omega_1|\mathbf{x}), & \text{当 } P(\omega_2|\mathbf{x}) > P(\omega_1|\mathbf{x}) \\ P(\omega_2|\mathbf{x}), & \text{当 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}) \end{cases} \quad (2-7)$$

## 4.2.5 最小错误率的说明

- 最小错误率的说明（设**C=2**，**D=1**）

- 错误率P(e)的推导

- 做 $\omega_1$ 判别时的错误概率

$$P(e_{12}) = \int_{\mathfrak{R}_1} P(\omega_2 | x) p(x) dx = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx$$

- 做 $\omega_2$ 判别时的错误概率

$$P(e_{21}) = \int_{\mathfrak{R}_2} P(\omega_1 | x) p(x) dx = \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

- 总错误概率

$$P(e) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx + \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

## 4.2.5 最小错误率的说明

- 最小错误率的说明（设**C=2**，**D=1**）

- 再假设t为唯一分界点（**C=2**，**D=1**）

- 做 $\omega_1$ 判别时的错误概率

$$P(e_{12}) = \int_{-\infty}^t P(\omega_2) p(x | \omega_2) dx$$

- 做 $\omega_2$ 判别时的错误概率


$$P(e_{21}) = \int_t^{\infty} P(\omega_1) p(x | \omega_1) dx$$

- 总错误概率

$$P(e) = \int_{-\infty}^t P(\omega_2) p(x | \omega_2) dx + \int_t^{\infty} P(\omega_1) p(x | \omega_1) dx$$



## 4.2.5 最小错误率的说明



$$P_1(e) = \int_{R_2} p(\mathbf{x} | \omega_1) d\mathbf{x}$$

$$P_2(e) = \int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x}$$

## 4.2.5 最小错误率的说明

- 推广到多类（任意**C**类）
  - 已知条件和问题
  - **C**类**D**维问题：  $\omega_1$  ,  $\omega_2$  ,  $\dots$  ,  $\omega_C$
  - 先验概率：  $P(\omega_1)$  ,  $P(\omega_2)$  ,  $\dots$  ,  $P(\omega_C)$
  - 类条件概率密度函数：  $p(x | \omega_1)$  ,  $p(x | \omega_2)$  ,  $\dots$  ,  $p(x | \omega_C)$
  - 发生了一个随机事件，其观察值为：特征向量 $x$
  - 求最小错误率分类器

## 4.2.5 最小错误率的说明

- 推广到多类（任意**C**类）
  - 判别函数
    - $P(\omega_i|x) = p(x|\omega_i) P(\omega_i) / p(x) \quad i = 1, \dots, C$
  - 决策规则
    - 对于未知样本 $x$ ，若 $P(\omega_j|x) = \max P(\omega_i|x)$ ，则 $x \in \omega_j$

## 4.2.6 特点

- 最小错误率**Bayes**决策的特点
  - 已知条件多——各类概率分布
  - 最小错误率——概率意义上最优
  - 非线性分类器
  - 设计过程复杂

## 4.3 最小风险Bayes决策

- 4.3.1 问题的提出
- 4.3.2 决策规则
- 4.3.3 其它说明
- 4.3.4 特点

## 4.3.1 问题的提出

- 最小错误率**Bayes**决策
  - 最小错误率——概率意义上最优
  - 工程上是否最优？
- 错误分类的结果、代价或风险会是怎样的？
  - 考虑癌细胞图像识别的例子
- 出错的可能情况
  - 正常细胞 $\omega_1$ 错分为异常 $\omega_2$
  - 异常细胞 $\omega_2$ 错分为正常 $\omega_1$

## 4.3.1 问题的提出

- 区别状态和决策概念

- 状态：识别的目的是分类，把样本归类于其可能的自然状态（即类别）之一，将这种自然状态简称为状态，记为 $\omega$
- 状态空间：所有可能的状态的集合构成状态空间，记为 $\Omega$

## 4.3.1 问题的提出

- 区别状态和决策概念

- 决策：把样本归类于某个状态，或不能进行归类，都是决策，记为 $\alpha$
- 决策空间：所有可能的决策（包括拒绝决策）的集合构成决策空间，记为 $A$



## 4.3.1 问题的提出

- 已知条件（类别**C = 2**，决策**A = 2**）
  - $\omega_1$ 、 $P(\omega_1)$ 、 $p(x | \omega_1)$ 和 $\omega_2$ 、 $P(\omega_2)$ 、 $p(x | \omega_2)$
  - $\Omega = \{\omega_1, \omega_2\}$
  - $A = \{\alpha_1, \alpha_2\}$
  - 定义损失函数 $\lambda(\alpha_i, \omega_j)$ ，简记 $\lambda_{ij}$
  - 发生了一个随机事件，其观察值为特征向量 $x$
- 求最小风险分类器

## 4.3.2 决策规则

- 判别函数

- $P(\omega_j | x) = p(x | \omega_j) P(\omega_j) / p(x) \quad j = 1, 2$

- $R(\alpha_i | x) = E[\lambda(\alpha_i, \omega_j) | x] = \lambda_{i1} P(\omega_1 | x) + \lambda_{i2} P(\omega_2 | x) \quad i = 1, 2$

- 决策规则

- 对于未知样本 $x$ ，若 $R(\alpha_k | x) = \min R(\alpha_i | x)$ ，则 $x \in \omega_k$ ，即决策 $\alpha_k$

## 4.3.2 决策规则

- 推广到任意情况（**C**个类别，**A**个决策）
  - $\omega_j$ 、 $P(\omega_j)$ 、 $p(x|\omega_j)$   $j = 1, \dots, C$
  - $\Omega = \{\omega_1, \omega_2, \dots, \omega_C\}$
  - $A = \{\alpha_1, \alpha_2, \dots, \alpha_A\}$
  - 定义损失函数 $\lambda(\alpha_i, \omega_j)$ ，简记 $\lambda_{ij}$
  - 发生了一个随机事件，其观察值为特征向量 $x$
  - 求最小风险分类器

## 4.3.2 决策规则

- 判别函数

- $P(\omega_j | x) = p(x | \omega_j) P(\omega_j) / p(x) \quad j = 1, 2, \dots, C$

- $R(\alpha_i | x) = E[\lambda(\alpha_i, \omega_j) | x] = \sum_{j=1} \lambda(\alpha_i, \omega_j) P(\omega_j | x) \quad i = 1, 2, \dots, A$

- 决策规则

- 对于未知样本 $x$ ，若 $R(\alpha_k | x) = \min R(\alpha_i | x)$ ，则 $x \in \omega_k$ ，即决策 $\alpha_k$

## 4.3.3 其它说明

- 最小风险与最小错误率的关系

- 0-1损失函数

$$\begin{aligned}\lambda(\alpha_i, \omega_j) &= 0 & i=j \\ \lambda(\alpha_i, \omega_j) &= 1 & i \neq j\end{aligned}$$

$$R(\alpha_i, x) = E[\lambda(\alpha_i, \omega_j)] = \sum_{j=1} \lambda(\alpha_i, \omega_j) P(\omega_j | x)$$

$$R(\alpha_i, x) = \sum_{\substack{j=1 \\ j \neq i}} P(\omega_j | x) = 1 - P(\omega_i | x)$$

## 4.3.3 其它说明

- 最小风险与最小错误率的关系

$$R(\alpha_i, x) = \sum_{\substack{j=1 \\ j \neq i}}^L P(\omega_j | x) = 1 - P(\omega_i | x)$$

- 对于未知样本 $x$ ，若 $R(\alpha_k | x) = \min R(\alpha_i | x)$ ，则 $x \in \omega_k$
- 对于未知样本 $x$ ，若 $P(\omega_k | x) = \max P(\omega_i | x)$ ，则 $x \in \omega_k$
- 结论：最小错误率**Bayes**决策，等价于**0-1**损失函数的最小风险**Bayes**决策

## 4.3.4 特点

- 最小风险**Bayes**决策的特点
  - 已知条件多——各类概率分布及风险系数
  - 最小错误风险——概率意义上最优
  - 非线性分类器
  - 设计过程复杂

# 例题

- 1、已知
  - 甲类:  $P(\omega_1) = 0.7$ 和类条件概率密度函数 $p(x|\omega_1)$
  - 乙类:  $P(\omega_2) = 0.3$ 和类条件概率密度函数 $p(x|\omega_2)$
  - 今有待分类样本特征观察值 $x = 10$ , 且由函数曲线查得 $p(10|\omega_1) = 0.2$ ,  $p(10|\omega_2) = 0.5$
  - (1)试用最小错误率Bayes决策对样本 $x = 10$ 进行分类
  - (2)试用最小风险Bayes决策对该样本进行分类, 设 $\lambda_{11}=\lambda_{22}=0$ ,  $\lambda_{12}=2$ ,  $\lambda_{21}=1$



## 4.4 最小最大决策

- 4.4.1 问题的提出
- 4.4.2 期望损失
- 4.4.3 最小最大风险
- 4.4.4 特点

## 4.4.1 问题的提出

- 已知条件和问题（**C = 2**情况）
  - 先验概率：考虑 $P(\omega_1)$  和 $P(\omega_2)$ 未知或不确定的情况
  - 此时绝对意义的最小风险不存在
  - 如何求Bayes分类器
- 思路
  - 假设 $P(\omega_1)$  和 $P(\omega_2)$ 确定
  - 设计一系列最小风险Bayes分类器
  - 取其中最大风险为最小的一个来用
  - 目的是控制最大风险

## 4.4.1 问题的提出

- 问题（类别**C = 2**，决策**A = 2**）
  - $\omega_1$ 、 $p(x | \omega_1)$ 和 $\omega_2$ 、 $p(x | \omega_2)$
  - $\Omega = \{\omega_1, \omega_2\}$
  - $A = \{\alpha_1, \alpha_2\}$
  - 损失函数 $\lambda(\alpha_i, \omega_j)$ ，简记 $\lambda_{ij}$
  - 发生了一个随机事件，其观察值为特征向量 $x$
- 求最小最大风险分类器

## 4.4.2 期望损失

- 期望损失的推导（回顾最小错误率证明）

$$P(e) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx + \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

$$P(e_{12}) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx$$

$$P(e_{21}) = \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

## 4.4.2 期望损失

- 期望损失的推导

联合或条件的  
形式均可

$$\begin{aligned} R &= \int R(a(x)|x)p(x)dx = \int_{\mathcal{X}_1} R(a_1|x)p(x)dx + \int_{\mathcal{X}_2} R(a_2|x)p(x)dx \\ &= \int_{\mathcal{X}_1} [\lambda_{11}P(\omega_1)p(x|\omega_1) + \lambda_{12}P(\omega_2)p(x|\omega_2)]dx + \int_{\mathcal{X}_2} [\lambda_{21}P(\omega_1)p(x|\omega_1) \\ &\quad + \lambda_{22}P(\omega_2)p(x|\omega_2)]dx \end{aligned}$$

$P(\omega_2) = 1 - P(\omega_1)$ , 代入

## 4.4.2 期望损失

- 期望损失的推导

$$R = \lambda_{22} + (\lambda_{12} - \lambda_{21}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x} + P(\omega_1) [(\lambda_{11} - \lambda_{22}) \\ + (\lambda_{21} - \lambda_{11}) \int_{\mathcal{R}_2} p(\mathbf{x} | \omega_1) d\mathbf{x} - (\lambda_{12} - \lambda_{22}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x}]$$

$$a = \lambda_{22} + (\lambda_{12} - \lambda_{21}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x}$$

$$b = (\lambda_{11} - \lambda_{22}) + (\lambda_{21} - \lambda_{11}) \int_{\mathcal{R}_2} p(\mathbf{x} | \omega_1) d\mathbf{x} - (\lambda_{12} - \lambda_{22}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x}$$

推导思路：替换后改成只有 $P(\omega_2)$ 有关的形式

## 4.4.3 最小最大风险

- 最小最大风险的解

- 任给 $P(\omega_1)^*$ 的值,  $P(\omega_2)^* = 1 - P(\omega_1)^*$ 
  - ↓
- 求对应的最小风险Bayes分类器, 设决策域为 $R_1$ 和 $R_2$ 
  - ↓
- 计算对应的 $a^*$ 和 $b^*$ , 得到 $R^* = a^* - b^* P(\omega_1)^*$  (注意!  $R_1 R_2$ 随 $P(w)$ 变, 即决策会根据先验改变。故 $R$ 和 $P(w)$ 不是线性)
  - ↓
- 重复上述计算步骤, 得到一系列最小风险Bayes分类器, 并 可得 $P(\omega_1)^* \text{——} R^*$  关系曲线
  - ↓
- 比较所有最大风险, 取其中最小的一个, 作为最终的分类器

## 4.4.4 最小最大决策

- 最小最大决策的特点
  - 已知条件多——各类概率分布及风险系数
  - 最小最大风险——概率意义上最优
  - 非线性分类器
  - 设计过程很复杂



## 4. 5 Bayes分类器设计

- 4.5.1 原理设计
- 4.5.2 Bayes决策面
- 4.5.3 错误率估计
- 4.5.4 其它

## 4.5.1 原理设计

- 两类情况（**C=2**）设计方法一

- 定义判别函数 $g(x)$

- ①  $g(x) = P(\omega_1 | x) - P(\omega_2 | x)$

- ②  $g(x) = p(x | \omega_1)P(\omega_1) - p(x | \omega_2)P(\omega_2)$

- ③  $g(x) = \ln \frac{p(x | \omega_1)}{p(x | \omega_2)} + \ln \frac{P(\omega_1)}{P(\omega_2)}$

- 决策面H方程

- $g(x) = 0$


## 4.5.1 原理设计

- 两类情况（**C=2**）设计方法一

- 决策规则

- 对于未知样本 $x$ ，若 $g(x) > 0$ ，则 $x$ 决策为 $\omega_1$ 类
- 若 $g(x) < 0$ ，则 $x$ 决策为 $\omega_2$ 类

- 原理图



## 4.5.1 原理设计

- 两类情况（**C=2**）设计方法二

- 定义判别函数 $g_1(x)$ 和 $g_2(x)$

- ①  $g_i(x) = P(\omega_i | x)$

- ②  $g_i(x) = p(x | \omega_i) P(\omega_i)$

- ③  $g_i(x) = \ln p(x | \omega_i) + \ln P(\omega_i)$

- 决策面H方程

- $g_1(x) = g_2(x)$

## 4.5.1 原理设计

- 两类情况（**C=2**）设计方法二
  - 决策规则
    - 对于未知样本 $x$ ，若 $g_1(x) > g_2(x)$ ，则 $x$ 决策为 $\omega_1$ 类
    - 若 $g_1(x) < g_2(x)$ ，则 $x$ 决策为 $\omega_2$ 类
  - 原理图

## 4.5.1 原理设计

- 多类情况（**C**任意）设计方法
  - 定义判别函数 $g_i(\mathbf{x})$   $i = 1, 2, \dots, C$ 
    - ①  $g_i(\mathbf{x}) = P(\omega_i | \mathbf{x})$
    - ②  $g_i(\mathbf{x}) = p(\mathbf{x} | \omega_i) P(\omega_i)$
    - ③  $g_i(\mathbf{x}) = \ln p(\mathbf{x} | \omega_i) + \ln P(\omega_i)$
  - 决策面H方程
    - $g_i(\mathbf{x}) = g_j(\mathbf{x})$   $i, j = 1, 2, \dots, C$


## 4.5.1 原理设计

- 多类情况（**C**任意）设计方法

- 决策规则

- 对于未知样本 $x$ ，若 $g_j(x) = \text{MAX } g_i(x)$ ，则 $x$ 决策为 $\omega_j$ 类

- 原理图



## 4.5.2 正态分布决策面

- 单变量正态分布 / 一元正态分布

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}$$



## 4.5.2 正态分布决策面

- 多变量正态分布 / 多元正态分布

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) \triangleq \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp \left[ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right]$$

$$\boldsymbol{\mu} = E\{\mathbf{x}\}$$

$$\boldsymbol{\Sigma} = E\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T\}$$



## 4.5.2 正态分布决策面

- 多元正态分布的性质

- 均值与方差
- 等概率密度点的轨迹

正态分布的等密度点的轨迹为超椭球面

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = \text{常数}$$



$$\gamma^2 = (x - \mu)^T \Sigma^{-1} (x - \mu)$$

## 4.5.2 正态分布决策面

- 多元正态分布的性质

- 不相关性 & 独立性:          不相关性 = 独立性

$$\begin{aligned}\sigma_{ij}^2 &= E[(x_i - \mu_i)(x_j - \mu_j)], \quad i, j = 1, 2, \dots, d, i \neq j \\ &= E(x_i - \mu_i) \cdot E(x_j - \mu_j) \\ &= 0\end{aligned}$$

$$\Sigma = \begin{bmatrix} \sigma_{11}^2 & \cdots & 0 \\ \vdots & \ddots & \\ 0 & \cdots & \sigma_{dd}^2 \end{bmatrix}$$

$$\Sigma^{-1} = \begin{bmatrix} 1/\sigma_{11}^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1/\sigma_{dd}^2 \end{bmatrix}$$

## 4.5.2 正态分布决策面

- 多元正态分布的性质

- 边缘分布: 正态分布
- 条件分布: 正态分布
- 线性组合: 正态分布

## 4.5.2 正态分布决策面

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\}$$

- 正态分布时分类器的决策面方程

- 判别函数

③  $g_i(\mathbf{x}) = \ln p(\mathbf{x} | \omega_i) + \ln P(\omega_i)$

$$g_i(\mathbf{x}) = -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

- 决策面方程

$$g_i(\mathbf{x}) = g_j(\mathbf{x})$$

$$-\frac{1}{2} [(\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) - (\mathbf{x} - \mu_j)^T \Sigma_j^{-1} (\mathbf{x} - \mu_j)] - \frac{1}{2} \ln \frac{|\Sigma_i|}{|\Sigma_j|} + \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$

## 4.5.2 正态分布决策面

- 正态分布时分类器的决策面方程

- 二次型判别函数

展开

$$\begin{aligned}g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i) \\&= \mathbf{x}^T \mathbf{W}_i \mathbf{x} + \mathbf{w}_i^T \mathbf{x} + w_{i0}\end{aligned}$$

$$\mathbf{W}_i = -\frac{1}{2} \boldsymbol{\Sigma}_i^{-1} \quad (d \times d \text{ 矩阵})$$

$$\mathbf{w}_i = \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i \quad (d \text{ 维列向量})$$



$$w_{i0} = -\frac{1}{2} \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

- 决策面方程

相减

## 4.5.2 正态分布决策面

- 决策面示例



(d) 双曲线

(e) 直线



**THE END !**

